IA-NAHA

Intelligence Artificielle appliquée au Sport et à la Nutrition

RAPPORT DE MACHINE LEARNING

L3 MIASHS Mars 2026

Prédiction du temps de sommeil d'une Population sportive

Équipe
Noah CHAYRIGUES
Arthur FESCHET
Haitham ALFAKHRY
Yann BROWNE

Encadrement
Sandra Bringay
Namrata Patel
Théodore Michel-Picque

1. Introduction et problématique

Ce rapport présente la partie Machine Learning du projet IA-NAHA : la construction, la validation et l'analyse critique d'un modèle prédictif du temps de sommeil d'un sportif à partir de ses données d'activité physique journalière.

Objectifs

Nous sommes face à un problème de **régression**,

- **Ce qu'on cherche à prédire (Target) :** Le temps de sommeil total.
- **Ce qu'on utilise pour y arriver (Features) :** Les données biométriques et sportives (nombre de pas, âges, stress etc.).

L'idée de ce notebook est de répondre à une question concrète : peut-on utiliser le Machine Learning pour anticiper les besoins en sommeil d'une personne en se basant sur son activité physique de la journée ?

2. Préparation des données et choix méthodologiques

2.1 Filtrage sur la population sportive

La base globale contient des profils sédentaires et des profils actifs mélangés. Entraîner un modèle sur cet ensemble hétérogène lui aurait appris à distinguer un sédentaire d'un sportif ce qui est insuffisant au lieu de comprendre les nuances de la récupération physique. De ce fait notre projet s'adressant principalement à des sportifs, ce filtrage est une nécessité.

Deux critères complémentaires, alignés sur les recommandations OMS, ont été appliqués. Il suffit de valider l'un des deux pour être qualifié d'actifs :

> Séance structurée ≥ 30 min à intensité modérée ou élevée.
> Mode de vie actif : ≥ 8 000 pas quotidiens, qui est un seuil scientifiquement validé par l'OMS après des recherches sur celle-ci.

2.2 Deux bases, deux rôles distincts

Le projet mobilise deux fichiers sportifs : activite_uniquement_sportifs.csv (10 features, base principale) et sommeil_uniquement_sportifs.csv (7 features, base de validation croisée). Cette séparation n'est pas un choix technique arbitraire : elle reflète le fonctionnement réel des capteurs, l'activité est mesurée en journée, tandis que le sommeil est enregistré la nuit. Les deux bases ne sont donc pas fusionnées, mais analysées de manière comparative. Cela nous permettra de vérifier la véracité des données.

2.3 Une variable qui influence trop (Data Leakage)

Lors des premiers tests, le modèle Random Forest affichait un R^2 parfait avec une erreur de 3 minutes. Ce score, trop parfait pour des données comportementales réelles, a immédiatement suscité un doute. L'investigation a révélé la cause : la variable *quality_of_sleep* était incluse dans les features.

Or cette variable mesure la qualité d'une nuit déjà passée. Au moment où l'utilisateur consulte l'application le soir, cette information n'existe pas encore. Inclure cette variable revient à donner la réponse à l'algorithme avant l'examen. Nous en avons déduit que le modèle trichait et n'apprenait pas correctement. C'est pourquoi nous avons décidé de supprimer cette variable dans nos modèles.

2.4 Analyse d'un dataset non réel

Sur la base Sommeil, tous les modèles atteignaient un $R^2 \geq 0.98$ avec moins de 5 minutes d'erreur. Plutôt que de s'en réjouir, nous avons décidé de pousser l'analyse car nous avons trouvé que ce score était encore beaucoup trop élevé. En inspectant les observations brutes (base de données) nous avons remarqué que des individus partageant la même profession, le même âge et le même niveau de stress avaient exactement le même temps de sommeil au dixième d'heure près. Aucune vraie population humaine ne se comporte ainsi.

Ce dataset Kaggle est très probablement synthétique généré par une formule mathématique, non par de vrais individus. De ce fait l'algorithme ne prédit pas : il retrouve une équation préexistante, ces scores ne sont pas représentatifs de performances réelles. C'est pourquoi nous décidons que la base Sommeil soit abandonnée pour la modélisation finale, au profit de la base Activité, dont les données, bien que plus imparfaites et désordonnées, représentent un défi scientifique plus pertinent et reflètent mieux la réalité.

2.5 Tension artérielle : entre précision et simplicité d'utilisation

L'une des décisions majeures de notre modélisation a été l'exclusion de la variable *blood_pressure* (tension artérielle). Techniquement, cette variable améliorait le score du R^2, cependant nous avons décidé de la supprimer pour les raisons suivantes :

Le parcours utilisateur cible :

Lorsqu'un sportif se connecte sur l'interface IA-NAHA, son expérience doit être fluide. S'il doit remplir un formulaire pour obtenir sa prédiction de récupération :

- Variables retenues : Stress ressenti (échelle de 1 à 10), type d'activité (Yoga, HIIT, etc.), nombre de pas. Ce sont des données déclaratives que l'utilisateur connaît instantanément.
- Variable exclue : La tension artérielle (ex : 126/84 mmHg), c'est une donnée médicale qui nécessite un tensiomètre.

Le constat technique :

Inclure une variable que l'utilisateur ne peut pas fournir sans matériel médical crée une barrière à l'entrée. En Data Science, un modèle parfait que personne n'alimente

est un modèle inutile. Nous avons donc fait le choix conscient de sacrifier quelques points de précision mathématique pour garantir l'utilisabilité du site.

Note méthodologique : Ce choix transforme notre IA d'un outil médical complexe en un coach virtuel accessible, capable de donner une recommandation en moins de 30 secondes de saisie.

2.6 Mise à l'échelle et étanchéité Train/Test

Les variables présentaient des échelles radicalement différentes (10 000 pour les pas, 1 à 10 pour le stress). De ce fait sans normalisation, les algorithmes accordaient plus de poids aux grandes valeurs numériques indépendamment de leur importance réelle. Un *StandardScaler* a été utilisé pour ramener toutes les variables à la même échelle et permettre l'analyse.

Pour que l'IA reste honnête, nous avons utilisé un Pipeline. Il sert de « cloison étanche » : le StandardScaler apprend les échelles uniquement sur les données d'entraînement et reste totalement « aveugle » vis-à-vis du jeu de test. Cela nous permet de vérifier que l'IA fonctionnera vraiment quand un nouvel utilisateur viendra remplir ses données sur notre site.

3. Entraînement et résultats, utilisation d'un Découpage 80/20

Ce ratio 80/20 est le standard pour valider la fiabilité de l'IA. On utilise 80% des données pour l'apprentissage et on garde 20% pour le test final, cela permet de vérifier si le modèle sait généraliser ou s'il a juste appris par cœur. C'est indispensable pour simuler l'arrivée d'un nouvel utilisateur sur le site et mesurer l'erreur réelle.
Ainsi cinq algorithmes ont été mis en concurrence sur les deux bases sportives. Le tableau suivant présente les scores R^2 et RMSE obtenus sur le jeu de test (20% des données).

Modèle	R^2 Activité	RMSE Activité	R^2 Sommeil	RMSE Sommeil
Régression Linéaire	0.142	0.85 h	0.981	0.11 h
KNN (K=5)	-0.022	0.93 h	0.990	0.08 h
Random Forest	0.116	0.86 h	0.988	0.09 h
Gradient Boosting	0.130	0.85 h	0.990	0.08 h
XGBoost	0.018	0.91 h	0.989	0.09 h

Analyse des résultats
L'étude des deux bases montre des résultats très contrastés, nous obligeant à faire un choix méthodologique strict.

Base Activité : un signal cohérent mais partiel

Le score de R^2 plafonne à 0,14, c'est un résultat modeste mais représentatif des données de santé : le sport explique une tendance, mais ne peut pas prédire la totalité du sommeil. L'échec du KNN (score négatif) est intéressant : il prouve que deux sportifs ayant la même morphologie et la même activité ne dorment pas forcément de la même manière. La Régression Linéaire est le modèle le plus stable, confirmant que l'influence du sport sur le repos suit une logique directe et facile à interpréter.

Base Sommeil : une précision artificielle
Les scores dépassent 0,98 pour tous les modèles. En analyse de données comportementales, un tel résultat est suspect. L'examen des lignes montre que des profils très différents affichent des temps de sommeil rigoureusement identiques au dixième près : c'est le signe d'un jeu de données synthétique (généré par algorithme). Par rigueur, nous avons décidé d'écarter ces résultats comme dit précédemment pour ne pas baser notre projet sur des données qui ne reflètent pas la réalité humaine.

4. Validation croisée

K-Fold (K=5) - Robustesse des 2 meilleurs modèles

Un seul découpage 80/20 peut produire des résultats liés au hasard du tirage. La validation K-Fold (K=5) a été appliquée aux deux meilleurs modèles sur la base Activité : Régression Linéaire et Gradient Boosting. Nous avons choisi le K-Fold pour être certains que notre score n'est pas un simple "coup de chance" dû au hasard du découpage 80/20. En découpant la base en 5 et en répétant l'opération, nous prouvons que la Régression Linéaire est le modèle le plus régulier. C'est une sécurité pour garantir que l'IA ne s'effondrera pas sur de nouvelles données.

Résultat : la Régression Linéaire surpasse le Gradient Boosting sur les 5 folds, avec le meilleur R^2 moyen et la plus grande stabilité. Elle est retenue comme le meilleur modèle.

Leave-One-Out - Validation ultime

Le choix du LOO est le plus proche de la réalité de notre futur site. On simule l'arrivée d'un nouvel utilisateur inconnu : l'IA apprend sur tout le groupe sauf un, et doit deviner son sommeil. C'est la méthode la plus honnête pour valider que notre coach virtuel saura s'adapter à n'importe quel nouvel inscrit sans avoir besoin de le connaître d'avance.

Pour des raisons de temps de calcul, le LOO a été lancé sur 200 profils représentatifs (200 entraînements complets du modèle). En théorie il couvrirait les 2 011 sportifs de la base pour permettre une analyse complète.

On obtient une erreur moyenne de 0,951 heure, soit environ 57 minutes d'erreur moyenne.

La majorité des sportifs sont prédits avec une erreur inférieure à 40 minutes. Les erreurs les plus élevées, comprises entre 2 et 2,5 heures, concernent des profils atypiques dont le sommeil n'est pas correctement capté par les variables physiques. Ces écarts s'expliquent généralement par des facteurs imprévus tels que des événements exceptionnels, un stress soudain ou un environnement perturbé.

5. Modèle final, choix et interprétation

Pourquoi la Régression Linéaire ?

Les performances du Gradient Boosting et de la Régression Linéaire étant très proches, nous avons privilégié la transparence. Pour un coach de santé, il est indispensable de pouvoir justifier une recommandation. C'est pourquoi la Régression Linéaire n'est pas une "boîte noire" : elle produit des coefficients clairs qui permettent d'expliquer à l'utilisateur que son besoin de sommeil augmente à cause de son stress ou de l'intensité de sa séance. C'est un choix d'IA explicable, essentiel pour gagner la confiance de l'utilisateur sur le site. Nous l'avons aussi choisi car elle nous permettait d'avoir le meilleur score de R^2.

Analyse des coefficients : la logique du modèle

Les poids attribués par la Régression Linéaire valident nos observations initiales. Le *stress_level* domine avec un coefficient de -0,4 : plus le stress augmente, plus la durée de sommeil prédite diminue. Inversement, l'intensité sportive possède un poids positif, car un effort intense appelle biologiquement plus de repos. Les critères morphologiques (âge, BMI) restent secondaires dans le calcul final. Ces résultats prouvent que l'IA ne calcule pas au hasard mais suit une logique physiologique cohérente, ce qui est indispensable pour donner des conseils crédibles aux utilisateurs du site.

Test d'inférence sur un profil fictif

Le modèle entraîné sur 100% de la base sportive prédit 7h28 de sommeil pour un homme de 28 ans, IMC 22.5, 50 min de sport à intensité moyenne, 10 500 pas quotidiens, stress 4/10, non-fumeur. Cette valeur est cohérente avec les recommandations de santé publiées pour ce profil type.

6. Étude de cohérence

La preuve par l'absurde

Un R^2 de 0.14 soulève une question légitime : cette limite vient-elle d'un problème dans notre code, dans nos données, ou de la complexité d'étude du sommeil ? Pour répondre rigoureusement, le même pipeline a été appliqué pour prédire 5 variables différentes de la base Activité, avec les mêmes 10 features d'entrée.

Le raisonnement est simple : si notre code était défaillant, tous les scores seraient mauvais. Si seul le sommeil résiste, c'est que la variable elle-même est difficile à prédire et non notre algorithme. Voici certaines de ses variables prédites :

Variable cible	Grad. Boosting	Random Forest	Régression Lin.	KNN
avg_heart_rate	0.800	0.780	0.464	0.660
calories_burned	0.360	0.316	0.155	0.031
bmi	0.002	-0.052	0.001	-0.176
sleep_hours	-0.084	-0.081	-0.005	-0.180
stress_level	-0.068	-0.089	-0.007	-0.144

***avg_heart_rate* (R^2=0.80) :** Résultat central de l'étude supplémentaire, le rythme cardiaque est prédit avec une excellente précision à partir des mêmes features. Cela certifie que le pipeline est correct et que les données sont fiables.

***calories_burned* (R^2=0.36) :** On observe un score positif mais modéré. Les calories dépendent aussi de la morphologie, incomplètement capturée par nos 10 features d'entrée.

***bmi, sleep_hours, stress_level* ($R^2 \leq 0$) :** Ici ces trois variables résistent aux capteurs d'activité. Le BMI dépend de l'alimentation et de la génétique. De plus le sommeil et le stress dépendent de facteurs invisibles aux montres connectées : caféine, lumière bleue, événements de vie, pensées.

Brève conclusion

Le modèle n'est pas en cause, on observe un coefficient de détermination de R^2=0,80 obtenu sur le rythme cardiaque avec les mêmes données montre que les limites observées pour le sommeil sont d'ordre scientifique plutôt que technique. En effet, le sommeil humain ne peut être entièrement appréhendé à partir de simples capteurs d'activité physique, ce qui explique la difficulté à en fournir une estimation précise.

7. Récapitulatif des choix techniques

Choix technique	Raison scientifique	Impact sur le projet
Suppression de quality_of_sleep	Éviter le Data Leakage	Modèle honnête et réaliste
Filtre sportifs (≥8 000 pas)	Réduire la variance de population	Modèle spécialisé sur la cible
Suppression de blood_pressure	Utilisabilité grand public	Accessible sans tensiomètre
Pipeline (StandardScaler)	Étanchéité Train/Test	Pas de faussement du test
Validation LOO (200 tours)	Robustesse sur chaque individu	RMSE réelle pour un nouvel utilisateur
Régression Linéaire retenue	Interprétabilité (santé)	Coefficients lisibles et justifiables

8. Erreurs rencontrées et solutions

Le biais de la qualité du sommeil (Data Leakage)

Lors des premiers tests, le modèle affichait un R^2 de 0,99. Cette performance irréaliste venait de la variable *quality_of_sleep* : le modèle utilisait la qualité d'une nuit déjà passée pour deviner sa durée. En conditions réelles, cette information est inconnue au moment de la prédiction. Nous avons donc supprimé cette variable pour garantir un modèle honnête et véritablement prédictif.

L'importance cruciale de la variable stress

Une tentative de modélisation sur la base gym_logs a montré des résultats incohérents. L'analyse de corrélation a révélé que le stress explique à lui seul environ 36% de la variance du sommeil (corrélation de -0,81). Nous avons donc pris la décision d'écarter toute base de données ne mesurant pas le niveau de stress, car l'activité physique seule ne suffit pas à prédire le repos.

L'hétérogénéité de l'échantillon (Sédentaires vs Sportifs)

Sur la base globale, l'IA passait plus de temps à différencier un sédentaire d'un sportif qu'à analyser la récupération réelle. Pour spécialiser notre modèle sur la cible IA-NAHA, nous avons appliqué un filtre strict : 8 000 pas quotidiens ou une séance de sport intense. Ce choix permet à l'IA de se concentrer sur les nuances de la récupération athlétique.

L'impossibilité de fusionner les sources isolées

Au départ, nous avions des fichiers séparés pour le sport et le sommeil. Sans identifiant commun (ID utilisateur ou Date), il était impossible de les relier sans créer des associations totalement aléatoires. Pour éviter d'entraîner l'IA sur des données fausses, nous avons choisi d'utiliser le Dataset Activité. Sa force est de proposer un suivi direct : pour chaque individu, l'activité physique est déjà rigoureusement associée à la nuit de sommeil correspondante.

La fuite d'information lors de la mise à l'échelle

Calculer la moyenne et l'écart-type sur l'ensemble de la base avant la séparation Train/Test est une erreur méthodologique : le modèle "voit" alors indirectement les données de test. Nous avons résolu ce problème en encapsulant le StandardScaler dans un Pipeline Scikit-Learn. L'étanchéité est ainsi totale : le calibrage se fait sur l'entraînement et s'applique aveuglément au test, comme pour un futur utilisateur du site

9. Conclusion et perspectives

Ce que nous avons démontré :

Le choix de la Régression Linéaire nous permet de proposer un modèle robuste et surtout transparent. Plutôt que de donner un chiffre sans explication, notre IA justifie sa prédiction par des coefficients lisibles, ce qui est indispensable pour un outil de santé.

La performance de 0,80 obtenue sur le rythme cardiaque (avec le même code) est notre meilleure preuve de réussite : elle démontre que notre pipeline technique est parfaitement au point. Le score plus faible sur le sommeil n'est pas une défaillance de l'algorithme, mais le reflet d'une réalité physiologique : le sport n'est qu'un facteur parmi d'autres. Enfin, notre marge d'erreur de 57 minutes (validée par le LOO) est tout à fait acceptable pour un coach en hygiène de vie, dont le but est de guider l'utilisateur et non de poser un diagnostic médical.

Pistes d'amélioration (IA-NAHA v2.0) Pour affiner nos prédictions et dépasser les limites actuelles, plusieurs axes de développement sont envisagés :

- **Facteurs environnementaux :** Intégrer des données sur l'exposition à la lumière bleue avant le coucher et la température de la chambre.
- **Horaires :** Analyser la régularité des cycles de sommeil (heures de coucher et de lever fixes).
- **Données nutritionnelles :** Exploiter le module CIQUAL de notre site pour mesurer l'impact de la caféine ou de l'alcool sur la nuit qui suit.
- **Capteurs sonores :** Utiliser des données pour détecter les micro-réveils durant la nuit.

Conclusion : Bilan et réponse à la problématique

Ce travail de modélisation nous a permis de répondre à notre question de départ : peut-on réellement prédire la récupération d'un sportif avec ses données d'activité ? La réponse est oui, mais avec une nuance importante. Si le sommeil reste un phénomène complexe influencé par des facteurs imprévisibles, notre modèle réussit à isoler l'impact concret du sport et du stress.

Nous avons privilégié la sincérité scientifique, nous refusons les scores artificiellement élevés de certains jeux de données, nous avons construit une IA réaliste (R^2 de 0,14). Notre test sur le rythme cardiaque (R^2 de 0,80) confirme d'ailleurs que notre méthode est solide techniquement : si le score sur le sommeil est plus bas, c'est à cause de la variabilité humaine et non d'une erreur de code. L'IA-NAHA n'est plus un simple concept théorique mais un outil fonctionnel. Avec une erreur moyenne de 57 minutes, le modèle est prêt à être intégré sur notre site web pour remplir sa mission : aider les sportifs à mieux comprendre leur corps et à adapter leur hygiène de vie. L'enjeu est maintenant de rendre ces calculs accessibles via notre site web, en transformant des coefficients mathématiques en conseils concrets pour aider les sportifs à mieux gérer leur hygiène de vie au quotidien.